


Trabajo Práctico 2a: Generación de Datos



Introducción

Para comenzar a trabajar con datos en Python 3 realizaremos el trabajo de codear una serie de generadores de datos con distribuciones específicas, que nos serán útiles a lo largo de la materia. Luego realizaremos algunas exploraciones visuales sobre los mismos.

Utilizaremos en la materia [Jupyter Notebooks](#), que permiten entremezclar código Python 3, imágenes generadas por código y texto Markdown, muy útiles para realizar exploraciones de datos y mostrar resultados.

Se puede descargar el entorno Jupyter para Python 3 y correr el código y el renderizado de los notebooks en la máquina local, o se puede utilizar [Google Colab](#) que provee un entorno de programación, ejecución de código y renderizado de notebooks en la nube. Sin embargo se debe tener en cuenta que para futuros trabajos prácticos puede ser impráctico el uso de Colab ya que las sesiones tienen un límite de tiempo de uso, y se deberán correr localmente o en un servidor Jupyter alternativo, sin límites de tiempo.

Se pide entregar uno o más Notebooks (recordar que el archivo .ipynb guarda internamente el output generado al correr el código, las figuras y el texto). Sería deseable que se pueda correr entero sin lanzar errores.

Trabajo Práctico 2a: Generación de Datos

Ejercicio

Prepare código Python que genere conjuntos de datos (de longitud dada n y tomando parámetros adicionales) de acuerdo a las siguientes descripciones:

a) **Diagonales**

Los datos tienen d inputs, todos valores reales, correspondientes a la posición de un punto en un espacio d -dimensional. El output es un factor binario correspondiente a la clase a la que pertenece el ejemplo.

La clase 1 corresponde a puntos generados al azar, provenientes de una distribución normal con centro en el $(1, 1, \dots, 1)$ y matriz de covarianza diagonal (todas las variables son independientes entre sí), con desviación estándar igual a $C * \sqrt{d}$.

La clase 0 tiene la misma distribución, pero está centrada en el $(-1, -1, \dots, -1)$.

Los parámetros a ingresar son d (número de dimensiones) y n (número de ejemplos), ambos enteros, y C (parámetro de la desviación estándar) número real.

De los n puntos generados, $n/2$ deben pertenecer a cada clase (se puede asumir a n par, o agregar o restar un punto a la generación).

La función debe generar como salida un arreglo de n datos o ejemplos de dimensión d , y un arreglo de n clases (binarias) correspondientes a los datos.

Se puede encontrar información sobre Gaussianas multidimensionales y el caso especial de una matriz diagonal en <http://cs229.stanford.edu/section/gaussians.pdf> (secciones 1 y 3).

b) **Paralelas**

Igual que lo anterior, pero ahora las normales se encuentran paralelas una respecto de la otra.

La clase 1 centrada en el $(1, 0, \dots, 0)$, y la clase 0 centrada en el $(-1, 0, \dots, 0)$.

El desvío estándar ahora será C , independiente del valor de d .

c) **Espirales Anidadas**

Los datos tienen 2 inputs, x e y , que corresponden a puntos generados al azar con una distribución uniforme dentro de un círculo de radio 1. El output es un factor binario correspondiente a la clase a la que pertenece el ejemplo.

La clase 0 corresponde a los puntos que se encuentran entre las curvas

$$\rho = \theta / (4 * \pi) \quad \text{y} \quad \rho = (\theta + \pi) / (4 * \pi) \quad (\text{en coord. polares})$$

La clase 1 corresponde a los puntos restantes.

De los n puntos generados, $n/2$ deben pertenecer a cada clase (se puede asumir a n par, o agregar o restar un punto a la generación).

La función debe generar como salida un arreglo de n datos de 2 dimensiones y un arreglo de clases que se correspondan con a los n ejemplos.

Trabajo Práctico 2a: Generación de Datos

Visualize los conjuntos de datos usando alguna librería útil para esto en Python3 (matplotlib/pyplot es la más usada). Cambie los parámetros de entrada ¿Varía como se espera? ¿Se ven bien las dispersiones?